



PHISHGUARD AI

ADA CORONADO MARTÍNEZ
06/06/2026

ÍNDICE

1. Introducción.....	3
2. Arquitectura del Sistema	4
2.1 Componentes principales.....	4
2.2 Flujo de datos	4
3. Las 4 Capacidades de PhishGuard AI	5
3.1 Análisis de phishing	5
3.2 Consulta de política de seguridad.....	5
3.3 Respuesta guiada a incidentes	5
3.4 Generación de reportes a GitHub	5
4. Problemas Encontrados y Soluciones.....	6
4.1 Rate limit de Google Gemini	6
4.2 Modelo de Groq dado de baja.....	6
4.3 Nodo Merge con error de configuración.....	6
4.4 Error de autenticación con GitHub	6
4.5 Window Buffer Memory sin session ID	7
4.6 ChatGPT no devolvía respuesta	7
4.7 ChatGPT respondía con su propio conocimiento.....	7
5. Configuración Técnica.....	9
5.1 Flujo de n8n	9
5.2 Custom GPT — Schema OpenAPI	9
5.3 Repositorio GitHub.....	9
6. Interfaces de Usuario	10
6.1 Chat interno de n8n	10
6.2 Custom GPT en ChatGPT	10
6.3 Interfaz web propia (HTML)	10
7. Conclusiones.....	11

1. Introducción

Este documento describe el proceso completo de implementación de PhishGuard AI, un asistente conversacional de ciberseguridad desarrollado para MIDTECH S.A. en el marco del TFC #include13 de la Fundación GoodJob.

El objetivo principal es automatizar la detección de phishing, la consulta de políticas de seguridad y la gestión de incidentes, integrando inteligencia artificial con flujos de automatización reales.

2. Arquitectura del Sistema

2.1 Componentes principales

Componente	
n8n Cloud	Plataforma de automatización que orquesta todo el flujo de trabajo
Groq AI (LLaMA 3.3)	Modelo de lenguaje que procesa y responde las consultas
GitHub	Almacenamiento de reportes de incidentes generados automáticamente
Custom GPT (ChatGPT)	Interfaz conversacional conectada al flujo vía webhook
HTML/CSS/JS	Interfaz web propia con diseño estilo terminal de ciberseguridad

2.2 Flujo de datos

1. El usuario escribe una consulta en ChatGPT o la interfaz web.
2. ChatGPT llama al webhook de n8n mediante una Action (OpenAPI).
3. n8n recibe la petición y la envía al AI Agent con el system prompt de PhishGuard.
4. El AI Agent procesa con Groq LLaMA 3.3 y genera la respuesta.
5. Si detecta una solicitud de reporte, genera un archivo Markdown y lo sube a GitHub.
6. La respuesta vuelve al usuario a través del nodo Respond to Webhook.

3. Las 4 Capacidades de PhishGuard AI

3.1 Análisis de phishing

Cuando el usuario pega un email sospechoso, el agente lo analiza e identifica:

- Nivel de riesgo: ALTO, MEDIO o BAJO
- Indicadores de fraude: dominios falsos, urgencia artificial, enlaces sospechosos
- Recomendación de acción concreta

Ejemplo de uso:

"Analiza este email: Estimado usuario, haga clic en <http://micr0soft-login.com...>"

3.2 Consulta de política de seguridad

El agente tiene acceso completo a la Política PSI-MIDTECH-2025-v2.1 y puede responder preguntas sobre:

- Contraseñas: mínimo 8 caracteres, cambio cada 180 días, historial de 5
- Cifrado: AES-256 en bases de datos, BitLocker en portátiles
- Backups: diario y semanal
- Cumplimiento normativo: GDPR, ISO 27001, ENS
- Limitaciones conocidas de la política actual

3.3 Respuesta guiada a incidentes

Cuando el usuario reporta un incidente, el agente le guía paso a paso según la Sección 7 de la política:

7. Detección: identificar el tipo y alcance del incidente
8. Contención: aislar sistemas afectados
9. Erradicación: eliminar la amenaza
10. Recuperación: restaurar los sistemas
11. Lecciones aprendidas: documentar y mejorar

3.4 Generación de reportes a GitHub

Al finalizar la gestión de un incidente, el agente puede generar un reporte formal en formato Markdown y subirlo automáticamente al repositorio de GitHub:

<https://github.com/NatsumiiiNara/tfc-asistente-ciberseguridad-y-compliance>

Los reportes se guardan en la carpeta /reportes/ con el nombre:

[incidente_YYYY-MM-DD_nombre_del_incidente.md](#)

4. Problemas Encontrados y Soluciones

4.1 Rate limit de Google Gemini

Problema:

El modelo original Google Gemini devolvía el error: "The service is receiving too many requests from you". La capa gratuita de Gemini tiene límites muy restrictivos de solicitudes por minuto.

Solución:

Se substituyó Google Gemini por Groq AI con el modelo llama-3.3-70b-versatile, que ofrece una capa gratuita con límites mucho más amplios y mayor velocidad de respuesta.

Aspecto	
Error original	Too many requests - Rate limit exceeded
Causa	Capa gratuita de Google Gemini muy restrictiva
Solución	Cambio a Groq AI (llama-3.3-70b-versatile)
Resultado	Success in ~900ms, sin límites en uso normal

4.2 Modelo de Groq dado de baja

Problema:

Al intentar usar el modelo llama3-8b-8192 se obtuvo el error: "The model llama3-8b-8192 has been decommissioned and is no longer supported".

Solución:

Se actualizó el modelo a llama-3.3-70b-versatile, que es el modelo recomendado actualmente por Groq para uso en producción.

4.3 Nodo Merge con error de configuración

Problema:

El nodo Merge mostraba el error: "You need to define at least one pair of fields in Fields to Match to match on". El modo multiplex requería campos de coincidencia que no aplicaban al caso de uso.

Solución:

Se cambió el modo del nodo Merge de "combine/multiplex" a "Append", que simplemente une los resultados de las dos ramas sin necesidad de campos de coincidencia.

4.4 Error de autenticación con GitHub

Problema:

El nodo HTTP Request para subir archivos a GitHub devolvía: "Authorization failed - please check your credentials". La credencial estaba configurada con Bearer en lugar del formato correcto de GitHub.

Solución:

La API de GitHub requiere el formato token en lugar de Bearer. Se actualizó la credencial Header Auth:

Campo	
Name	Authorization
Value (incorrecto)	Bearer ghp_XXXXXXX
Value (correcto)	token ghp_XXXXXXX

4.5 Window Buffer Memory sin session ID

Problema:

Al conectar ChatGPT al flujo mediante webhook, el nodo Window Buffer Memory devolvía: "No session ID found". Estaba configurado para leer el sessionId del Chat Trigger de n8n, pero las llamadas llegaban desde el webhook externo.

Solución:

Se cambió el parámetro Session ID de "Connected Chat Trigger Node" a "Define below" y se configuró una expresión que lee el sessionId del cuerpo del webhook:

```
{{ $('Webhook').item.json.body.sessionId ?? 'chatgpt-session' }}
```

4.6 ChatGPT no devolvía respuesta

Problema:

ChatGPT llamaba correctamente al webhook de n8n pero el flujo no devolvía respuesta. El nodo "When chat message received" no estaba configurado para usar el nodo Respond to Webhook.

Solución:

Se añadió un nodo Respond to Webhook al final del flujo y se configuró el trigger con Response Mode: "Using Respond to Webhook Node". También se ajustó el Response Body:

```
{ "output": "{{ $('Respuesta Normal').item.json.output }}" }
```

4.7 ChatGPT respondía con su propio conocimiento

Problema:

El Custom GPT respondía correctamente pero usando su conocimiento propio en lugar de llamar al flujo de n8n. Las instrucciones originales no eran suficientemente estrictas.

Solución:

Se actualizaron las instrucciones del Custom GPT para forzar el uso de la Action en cada mensaje:

REGLA ABSOLUTA: Para CUALQUIER mensaje, SIEMPRE llama primero a consultarPhishGuard.

5. Configuración Técnica

5.1 Flujo de n8n

Nodo	
When chat message received	Trigger para el chat interno de n8n
Webhook (POST /phishguard-api)	Trigger para llamadas externas (ChatGPT)
AI Agent	Orquesta el modelo con el system prompt de PhishGuard
Groq Chat Model	Modelo LLaMA 3.3 70B para generar respuestas
Window Buffer Memory	Memoria de conversación por sesión
¿Crear Reporte? (IF)	Detecta si la respuesta contiene ACTION: CREAR_REPORTE
Preparar Reporte (Code)	Genera el Markdown y lo convierte a base64
Subir a GitHub (HTTP)	Sube el archivo al repositorio via API de GitHub
Mensaje Éxito (Code)	Formatea el mensaje de confirmación con el enlace
Respuesta Normal (Code)	Devuelve la respuesta conversacional normal
Merge (Append)	Une los resultados de ambas ramas
Respond to Webhook	Devuelve la respuesta final al cliente externo

5.2 Custom GPT — Schema OpenAPI

El Custom GPT se conecta a n8n mediante una Action con el siguiente endpoint:

POST <https://adacoronado02.app.n8n.cloud/webhook/phishguard-api>

El cuerpo de la petición incluye:

- chatInput: mensaje del usuario
- sessionId: identificador de sesión para mantener el contexto

5.3 Repositorio GitHub

Los reportes se almacenan automáticamente en:

<https://github.com/NatsumiiiNara/tfc-asistente-ciberseguridad-y-compliance/tree/main/reportes>

Formato de nombre de archivo:

[incidente_YYYY-MM-DD_titulo_del_incidente.md](#)

6. Interfaces de Usuario

6.1 Chat interno de n8n

Disponible directamente en n8n Cloud. Útil para demostrar el flujo técnico y visualizar los logs de ejecución en tiempo real.

6.2 Custom GPT en ChatGPT

Accesible mediante el enlace:

<https://chatgpt.com/g/g-6a21aecbc68881918bf7ed687d8063ec-phishguard-ai-midtech>

Ventajas: interfaz familiar para el usuario, disponible desde cualquier dispositivo con ChatGPT Plus.

6.3 Interfaz web propia (HTML)

Diseño estilo terminal de ciberseguridad con:

- Colores corporativos: azul oscuro (#00D4FF) sobre fondo negro
- Botones de acceso rápido para las 4 capacidades
- Indicadores visuales de riesgo: ALTO en rojo, MEDIO en naranja, BAJO en verde
- Conexión directa al webhook de n8n

7. Conclusiones

PhishGuard AI demuestra cómo integrar inteligencia artificial con automatización real para resolver problemas concretos de ciberseguridad empresarial. Los principales logros del proyecto son:

- Detección automática de phishing con análisis contextual en lenguaje natural
- Consulta instantánea de políticas de seguridad complejas (GDPR, ISO 27001, ENS)
- Guía paso a paso en la gestión de incidentes según procedimientos reales
- Generación y almacenamiento automático de reportes formales en GitHub
- Integración con ChatGPT como interfaz de usuario mediante Custom GPT y Actions

Los problemas encontrados durante la implementación — rate limits, modelos deprecados, configuraciones de autenticación y webhooks — son representativos de los desafíos reales en proyectos de integración de IA, y su resolución demuestra capacidad técnica de diagnóstico y adaptación.

Firma:

Ada Coronado Martínez

ID SCOLA: Ex-1208

